

TECH CHALLENGE · FASE 2

Pipeline Híbrida de Alfabetização

Integrando dados públicos para apoiar políticas de alfabetização no Brasil

Guilherme Cosme

RM 372204 · Turma 1IAST · MBA AI Scientist · FIAP / POSTECH

 github.com/guillecosme/fiap-ai-scientist-tech-challenge-fase-02

Vídeo executivo (5 min): www.loom.com/share/ade3918fb4774c129402f385f178e717

O problema

A alfabetização até o final do 2º ano é um marco do desenvolvimento educacional, social e econômico. O país tem uma meta clara para acompanhar esse direito.

O Indicador Criança Alfabetizada mede o percentual de crianças que atingem o nível de leitura esperado. Sozinho, ele mostra onde estamos, mas não explica o porquê nem ajuda a agir.

Para isso, é preciso juntar fontes que hoje vivem separadas: metas, territórios e desempenho dos alunos.

743

pontos no Saeb: o corte que define uma criança alfabetizada

2030

meta para todas as crianças alfabetizadas ao fim do 2º ano

O dado certo, hoje, está espalhado

UF

Unidades da federação e
regiões

M
U
N

Municípios e vínculo com a
UF

ME
TA

Metas nacional, por UF e
por município

AL

Desempenho dos alunos
por rede

Integradas, essas fontes deixam de ser números soltos e passam a responder onde concentrar esforço, onde estão as maiores desigualdades e o que está melhorando ao longo do tempo.

A solução

Uma pipeline de dados que integra essas fontes de forma automática, confiável e barata, na nuvem.

1

Híbrida

Ingestão em lote e em tempo quase real

2

Medalhão

Camadas de bruto, tratado e analítico

3

Serverless

Paga pelo uso, sobe e destrói em minutos


4

Governada

Qualidade validada a cada rodada

Arquitetura da solução

Pipeline Híbrida de Alfabetização — Arquitetura na AWS (medalhão Bronze / Silver / Gold)



Terraform provisiona e destrói tudo, agnóstico à conta · LocalStack roda a mesma pipeline em dev, custo zero

Ingestão híbrida: cada dado no seu regime



Batch

O que é: carga periódica das bases estáveis, como job Glue agendado pelo EventBridge.

Na pipeline: UF, município e as três metas, lidas da Base dos Dados e gravadas no Bronze.

Por quê: referências mudam em lotes; recarregar tudo (overwrite) é simples e idempotente.

Trade-off: reprocessa a base inteira a cada rodada, aceitável pelo volume pequeno.



Streaming

O que é: ingestão de eventos em tempo quase real, via Kinesis e Lambda.

Na pipeline: produtor simula novas medições (município, rede, indicador) no Kinesis.

Por quê: medições chegam continuamente; tratar como evento encurta o caminho até a análise.

Trade-off: latência de micro-lote vs custo; Kinesis on-demand paga só pelo que passa.

Camadas medalhão: por que cada uma existe

1

Bronze

Dado bruto, como veio da fonte, particionado por data e versionado.

Por quê Preserva o histórico e permite reprocessar Silver e Gold quando a regra muda.

Trade-off Duplica armazenamento em troca de reprocessamento e auditoria.

2

Silver

Limpo, tipado, com chaves normalizadas e as bases integradas.

Por quê Cria uma fonte única e consistente; alunos batch e streaming no mesmo grão.

Trade-off Custo e complexidade de transformação em troca de simplicidade a jusante.

3

Gold


Star schema (dimensão e fato) e marts prontos, particionados por ano.

Por quê Desnormaliza para consulta rápida e leitura direta por BI e ML.

Trade-off Duplicação e pré-cálculo em troca de performance de consulta.

Gate de qualidade

Gate de qualidade — valida a Silver antes de promover para a Gold



Severidade: uma checagem crítica barra a promoção; uma checagem de aviso (warning) registra a métrica e segue. O gate roda também sobre a Gold, como última linha antes do consumo.

Trade-offs

Crítica x aviso.

Uma falha crítica barra a promoção; um aviso registra a métrica e segue. Rigor sem travar por qualquer anomalia.

Custo x risco.

Rodar as 11 checagens custa alguns segundos, barato perto do risco de um número errado chegar a um dashboard público.

Onde roda.

Entre Silver e Gold e também sobre a Gold, como última linha antes do consumo.

Custo, monitoramento e trade-offs

Serverless de ponta a ponta e observabilidade por CloudWatch e SNS. Abaixo, as escolhas que puxam o custo para baixo.




Glue



Kinesis



Lambda



Step Functions



Athena



S3



CloudWatch

Escolha	Alternativa	Por que reduz custo
Step Functions + EventBridge	MWAA (Airflow gerenciado)	Serverless por execução; MWAA cobra um ambiente sempre de pé
Parquet particionado	CSV / JSON	Colunar e comprimido; Athena cobra por byte lido, com partition pruning
Kinesis on-demand	Shards provisionados	Escala sozinho e cobra pelo que passa
Ciclo de vida no S3	Tudo em Standard	Bronze frio migra: Standard-IA aos 30 dias, Glacier aos 120
Glue G.1X, 2 workers	Cluster grande fixo	Dimensionado para o volume; cresce com o dado, sem custo fixo
Teto de bytes no Athena	Sem limite de leitura	Barra query cara antes de virar gasto

Rodou em escala real, com custo controlado

5.571

municípios e 27 UFs, território real da API pública do IBGE

11/11

checagens do gate de qualidade aprovadas na execução

R\$ 0

leitura da fonte no BigQuery, dentro da franquia de 1 TB/mês

Indicador por região em 2025, dos 5.571 municípios (mart da Gold)

Região	Indicador médio	Atingiram a meta
Sul	80,2%	37%
Sudeste	76,0%	42%
Centro-Oeste	72,0%	38%
Nordeste	61,1%	32%
Norte	59,2%	26%
Brasil	70,4%	36%

Valor e potencial de IA

A Gold sai pronta para alimentar modelos e análises. Três frentes concretas:

1

Antecipar

Prever quais municípios tendem a ficar abaixo da meta e agir antes do resultado consolidado.

Na Gold Insumo: fato por município (indicador_pct, gap_meta_pp, atingiu_meta) mais enriquecimento socioeconômico como base de treino.

2

Enxergar desigualdade

Comparar regiões e redes e identificar grupos em maior vulnerabilidade educacional.

Na Gold Insumo: clusterização sobre indicador, região, rede e distância da meta para achar padrões.

3

Decidir com dados

Priorizar recurso onde há maior distância da meta e medir o efeito das ações no tempo.

Na Gold Insumo: comparação meta vs resultado por UF e município e a evolução temporal ano a ano.

Dados públicos viram informação acionável

Uma pipeline moderna, barata e confiável, que transforma o indicador de alfabetização em apoio à política pública e já abre a porta para inteligência artificial.

Obrigado.

Vídeo da apresentação: www.loom.com/share/ade3918fb4774c129402f385f178e717